



IA353A - Neural Networks EC2

Rafael Claro Ito
(R.A.: 118430)

August 2020

Question 7

- 7.1 Transferência negativa
- 7.2 Camadas compartilhadas
- 7.3 MALSAR

Question 8

Considerando a camada q de uma rede neural MLP, temos:

$$x^{[q]} = f(W^{[q]}x^{[q-1]} + b)$$

Onde:

- $x^{[q]}$ é a saída da camada q após função de ativação;
- $W^{[q]}$ são os pesos dos neurônios da camada q ;
- $x^{[q-1]}$ é a entrada da camada q (saída da camada $q - 1$);
- $f(\cdot)$ é a função de ativação da camada q ;

Calculando a variância de ambos lados da equação anterior, temos:

$$\begin{aligned} x^{[q]} &= f(W^{[q]}x^{[q-1]} + b) \\ \text{Var}(x^{[q]}) &= \text{Var}(f(W^{[q]}x^{[q-1]} + b)) \end{aligned}$$

Devemos agora fazer algumas considerações:

- função de ativação $f(\cdot) = \tanh$, sendo que no início do treinamento trabalha-se com os pesos próximos à região linear (próximo de zero), evitando neurônios operando na região de saturação e favorecendo o aprendizado nas primeiras iterações. Desta forma, considerando a região linear, podemos aproximar a função \tanh para uma função identidade;
- W e x são independentes entre si;
- W é uma variável aleatória i.i.d. (independente e identicamente distribuída). Isso geralmente é verdade para a inicialização;
- x é uma variável aleatória i.i.d. (independente e identicamente distribuída). Embora nem sempre isso seja verdade (por exemplo, pixels de uma imagem geralmente apresentam alta correlação entre pixels ao redor), faremos essa consideração;

Continuando o desenvolvimento da equação anterior:

$$\text{Var}(x^{[q]}) = \text{Var}(f(W^{[q]}x^{[q-1]} + b))$$

A partir de i), temos:

$$\text{Var}(x^{[q]}) = \text{Var}(W^{[q]}x^{[q-1]} + b)$$

Se duas variáveis são independentes entre si, temos a igualdade:

https://en.wikipedia.org/wiki/Variance#Product_of_independent_variables:

$$\text{Var}(XY) = [\mathbb{E}(X)]^2 \text{Var}(Y) + [\mathbb{E}(Y)]^2 \text{Var}(X) + \text{Var}(X)\text{Var}(Y)$$

Vamos agora abrir o produto das matrizes W e x em uma soma dos produtos de seus termos w_i e x_i . Usando também a consideração dada por ii) e sabendo que b é uma constante (e portanto sua variância é zero), temos que:

$$\begin{aligned} \text{Var}(x^{[q]}) &= \text{Var}(W^{[q]}x^{[q-1]} + b) \\ \text{Var}(x^{[q]}) &= \text{Var}\left(\sum_{i=1}^{n^{[q-1]}} w_i^{[q]} x_i^{[q-1]}\right) \\ \text{Var}(x^{[q]}) &= \sum_{i=1}^{n^{[q-1]}} \text{Var}(w_i^{[q]} x_i^{[q-1]}) \\ \text{Var}(x^{[q]}) &= \sum_{i=1}^{n^{[q-1]}} [\mathbb{E}(w_i^{[q]})]^2 \text{Var}(x_i^{[q-1]}) + [\mathbb{E}(x_i^{[q-1]})]^2 \text{Var}(w_i^{[q]}) + \text{Var}(w_i^{[q]})\text{Var}(x_i^{[q-1]}) \end{aligned}$$

A partir de iii) e iv), temos que $\mathbb{E}(w_i) = 0$ e $\mathbb{E}(x_i) = 0$, sendo ambos W e x variáveis i.i.d. Assim:

$$Var(x^{[q]}) = \sum_{i=1}^{n^{[q-1]}} Var(w_i^{[q]}) Var(x_i^{[q-1]})$$

$$\boxed{Var(x^{[q]}) = n^{[q-1]} Var(w^{[q]}) Var(x^{[q-1]})}$$

Queremos provar que $b = \sqrt{\frac{3}{n^{[q-1]}}}$ para que a variância da entrada da camada q seja igual a variância da camada $q-1$.

Sabendo que a variância de uma variável aleatória que segue uma distribuição uniforme entre a e b , isto é, $X \sim \mathbb{U}[a, b]$, é dada por: $Var(X) = \frac{(b-a)^2}{12}$ (prova). Temos:

$$Var(x^{[q]}) = n^{[q-1]} Var(w^{[q]}) Var(x^{[q-1]})$$

$$Var(x^{[q]}) = n^{[q-1]} \cdot \frac{(b - (-b))^2}{12} \cdot Var(x^{[q-1]})$$

$$Var(x^{[q]}) = n^{[q-1]} \cdot \frac{(2b)^2}{12} \cdot Var(x^{[q-1]})$$

$$Var(x^{[q]}) = n^{[q-1]} \cdot \frac{4b^2}{12} \cdot Var(x^{[q-1]})$$

Como queremos $Var(x^{[q]}) = Var(x^{[q-1]})$, temos:

$$n^{[q-1]} \cdot \frac{4b^2}{12} = 1$$

$$b^2 = \frac{12}{4 \cdot n^{[q-1]}}$$

$$\boxed{b = \sqrt{\frac{3}{n^{[q-1]}}}}$$

Question 9

9.1 Principais seções do padrão de documentação

As principais seções do padrão de documentação de datasets são mostradas na seção 3 do artigo, intitulada “Questions and Workflow”. Os itens desta seção, assim como uma breve descrição são apresentados a seguir:

- **Motivação:** razões para a criação do dataset (propósito de tarefa específica, preenchimento de alguma lacuna na área), informações a cerca de quem ou qual grupo o criou, se houve alguma apoio ou financiamento para a construção do dataset.
- **Composição:** informações com respeito a composição do dataset, como por exemplo, do que se tratam os dados, se há rótulos e quais, quantidade de cada classe (se aplicável), divisão em treinamento/validação/teste recomendada, fontes de ruído nos dados, se os dados estão relacionados a pessoas, etc.
- **Processo de coleta:** informações sobre a construção do dataset permitindo outras pessoas re-construí-lo (quando aplicável) sem ter acesso a ele. Aqui temos perguntas do tipo, se os dados foram coletados de algum sensor ou humanos, se os dados foram observados diretamente, que tipo de pessoa participou do processo de coleta dos dados e se elas foram compensadas, se há algum aspecto ético envolvido, etc.
- **Pré-processamento/limpeza/rotulamento:** descrição sobre o processamento e metodologia usada nos dados crus (fornecendo-os quando possível) e informação do software usado para isso quando aplicável.
- **Uso:** quais os casos de uso deste dataset, links para artigos que usufruem do dataset em questão, situações em que o dataset não deve ser usado.
- **Distribuição:** informações a respeito da distribuição dos dados. Se serão ou não distribuídos, onde e como serão (página web, GitHub, API, compactado), quando, qual a licença de uso, etc.
- **Manutenção:** por fim, informações a respeito de quem está hospedando os dados, quem está dando manutenção e suporte no dataset, contato do responsável, se há alguma errata, planos de atualização (o quê e quando), suporte a versões anteriores, entre outros.

Dois exemplos de datasheet para dataset são mostrados no apêndice do artigo. Um para o dataset “Labeled Faces in the Wild” e outro para o dataset “Pang and Lee’s polarity”.

9.2 Artigos com propósitos similares

9.2.1 Artigo 1

O primeiro artigo é de um grupo da IBM Research e apresenta os FactSheets. Assim como os datasheets de componentes inspiraram o artigo usado como base desta questão, os SDoCs (supplier’s declarations of conformity) foram usados como base neste artigo de 2018 para propor os FactSheets.

- título: FactSheets: Increasing Trust in AI Servicesthrough Supplier’s Declarations of Conformity
- ano: 2018
- authors: Arnold et al. (IBM Research)
- arXiv: <https://arxiv.org/pdf/1808.07261.pdf>

9.2.2 Artigo 2

O segundo artigo também é de 2018 de um grupo da Google e apresenta os Model Cards. Um dos autores do artigo é o autor principal do artigo “Datasheets for Datasets” (Timnit Gebru), usado como base para esta questão. O artigo propõe um padrão de relatório para **modelos** treinados de machine learning, apresentando exemplos para dois modelos.

- título: Model Cards for Model Reporting
- ano: 2018
- authors: Mitchell et al. (Google)
- arXiv: <https://arxiv.org/pdf/1810.03993.pdf>

Question 10

10.1 EfficientNet

O artigo (Tan & Le, 2019) propõe uma forma de escalar modelos baseados em redes convolucionais (ConvNets), como por exemplo MobileNets e ResNet, levando em conta três parâmetros avaliados conjuntamente: profundidade, largura e resolução. Adicionalmente, os autores usam um método de NAS (*neural architecture search*) para encontrar um modelo base (baseline), para em seguida usar o método de escalamento proposto e obter uma família de modelos denominada *EfficientNets*, cujos resultados são impressionantes, sendo mais eficientes em termos de custo computacional (modelos menores e mais rápidos) e performance, com resultados melhores atingindo o estado da arte (SOTA) para base de dados como ImageNet, CIFAR-100 e outras.

Supondo que se queira um modelo maior que use 2^N mais recursos, propõe-se aumentar a rede multiplicando os três parâmetros pelas seguintes constantes: profundidade multiplicada por α^N , largura multiplicada por β^N e tamanho da imagem (resolução) por γ^N , onde α , β e γ são determinados através de um grid search no modelo original.

Na seção 3 do artigo, os autores mostram que o escalamento dos três parâmetros aumentam a performance dos modelos, mas cada um seguindo sua própria curva de saturação (figura 3 do artigo). Assim, eles chegam na primeira observação. A segunda observação foi obtida através dos experimentos cujos resultados são mostrados na figura 4 do artigo. Aqui é concluído que para uma melhor acurácia e eficiência, é necessário um balanceamento entre os fatores de escala de largura, profundidade e resolução.

O método de escalamento proposto é mostrado a seguir:

- profundidade: $d = \alpha^\phi$
- largura: $w = \beta^\phi$
- resolução: $r = \gamma^\phi$

sujeito a:

- $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$
- $\alpha \geq 1$
- $\beta \geq 1$
- $\gamma \geq 1$

O modelo base, denominado EfficientNet, foi obtido através de uma busca (NAS) multi-objetiva, procurando otimizar tanto a acurácia quanto FLOPS (operações de ponto flutuante por segundo). O função objetivo é dada por: $ACC(m) \times [FLOPS(m)/T]^w$, onde $ACC(m)$ e $FLOPS(m)$ é a acurácia e FLOPS do modelo m , T é o FLOPS alvo e w controla o *tradeoff* entre acurácia e FLOPS. Tomando $w = -0.07$, chega-se no modelo EfficientNet-B0.

A partir do modelo EfficientNet-B0, toma-se $\phi = 1$ (dobro de recursos) e busca-se as constantes através de um *grid search*. Encontra-se $\alpha = 1.2$, $\beta = 1.1$ e $\gamma = 1.15$, satisfazendo a restrição $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$. Em seguida, essas constantes são usadas para escalar diferentes modelos alterando o valor de ϕ , obtendo-se os modelos EfficientNet-B1 até B7. Além destes modelos, MobileNets e ResNets também foram escaladas seguindo essa regra.

A partir da seção 5 do artigo, são descritos os experimentos e resultados, discussões e conclusão. Conforme descrito no início da resposta desta questão, os resultados obtidos são impressionantes, ganhando tanto em performance (custo computacional) quanto em desempenho (acurácia), atingindo um novo SOTA na área de visão computacional e ConvNets.

10.2 FixEfficientNet

O segundo artigo (Touvron et al., 2020) na verdade é uma nota que complementa o artigo “Fixing the train-test resolution discrepancy”, que introduz o método denominado FixRes.

O artigo original mostra que as técnicas de *data-augmentation* usadas até então induziam uma discrepância entre o tamanho dos objetos visto pelo classificador durante o treinamento e durante a fase de teste. Assim, os autores propõem uma estratégia que otimiza a performance do classificador, empregando diferentes resoluções em teste e treinamento. Isso é feito através de um *fine-tuning* da rede na resolução de teste.

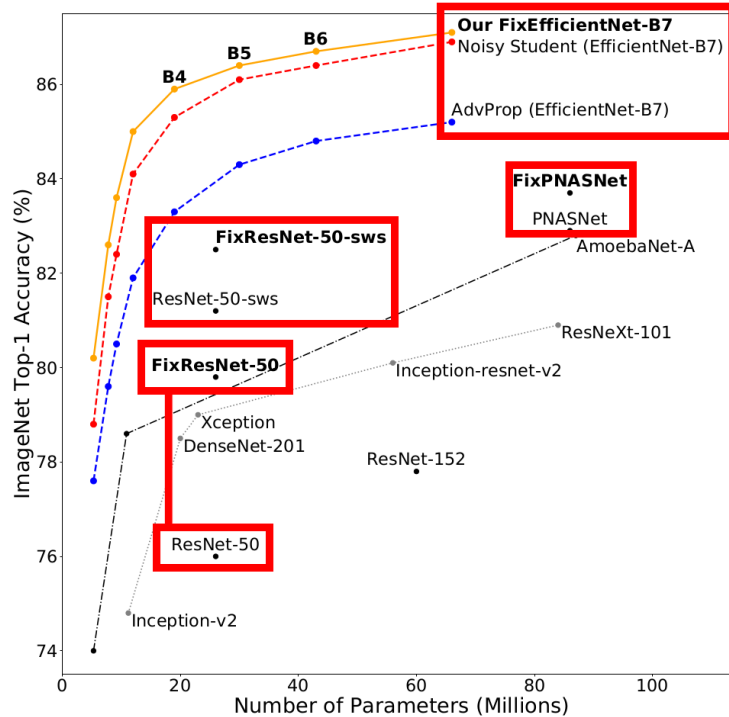


Figure 2: Comparação entre diversas redes com e sem a aplicação do método FixRes

A nota que complementa o artigo original toma as diversas redes renomadas, dentre elas as EfficientNets do item anterior, e aplica o método FixRes para obter uma família de redes denominadas FixEfficientNet. Os resultados podem ser vistos na figura 2.

Como podemos ver, em um curto período de tempo temos novos modelos SOTA. Alguns podem vir de arquiteturas novas (ex: EfficientNet em ConvNets e Transformers em NLP), outros de melhorias feitas na metodologia a partir de modelos já existentes (ex: escalamento apresentado no artigo da EfficientNet e método FixRes).